极客大学机器学习训练营
机器学习基本概念

王然

众微科技 AI Lab 负责人

二○二一年一月七日

大纲

1. 怎样学数学
2. 机器学习的各种角度和建模流程
3. 概率论和统计学复习
4. 极大似然估计
5. 贝叶斯公式和变分贝叶斯

大纲

1. 怎样学数学
2. 机器学习的各种角度和建模流程
3. 概率论和统计学复习
4. 极大似然估计
5. 贝叶斯公式和变分贝叶斯

为什么要学数学

- AI 的语言 → 不理解数学，不可能理解模型
- 创新的根基 → 看起来创新不多，但是实际上有很多地方可以创新，而且创新没有那么难
- 数学锻炼思维

数学的两种学法

- 把数学当做语言：不管它的意思，严格按照要求 → 我们主要讲方法
- 数学真正的学法，是以证明为目的的

数学真正的思考方式

核心：

- Frame and Hypotheses
- Elements and Relationships
- Patterns
- Intuition
- Retrospect and Empathetic
- Bucket(In/Out/New)
- Strategic minds

数学理论的主要内容

极客大学

- 机器学习的各种角度和建模流程
- 概率论和统计学基础概念复习
- 极大似然体系和 EM 算法
- 贝叶斯体系和 Variational Bayes 算法
- 矩阵代数：基本概念复习和 Tensor 求导

大纲

极客大学

1. 怎样学数学
2. 机器学习的各种角度和建模流程
3. 概率论和统计学复习
4. 极大似然估计
5. 贝叶斯公式和变分贝叶斯

为什么要掌握各种角度

- 最终目的：效果好，即准确性高
- 为了达到最终目的，必须从不同角度考虑

函数逼近的视角

- 最简单的是视角.
- 目标：给定 X 预测 y.
- 假设：存在真实的 $y = f_0(X)$.
- 如果我们知道 f_0，那么我们不需要做任工作。
- 但是我们不知道。

函数逼近的视角

极客大学

- 相比之下，我们观测 $\{X_i, y_i; i \in \mathfrak{I}\}$.
- 我们可以假设 $f \in \mathcal{F}$.
- 目标：给定一个损失函数 c, 最小化 $\sum_i c(f(X_i), y_i)$.
- 这个估计我们称之为 $\hat{f}$.

什么样的 $\hat{f}$ 是好的

- 最理想状况 $\hat{f} = f_0$；事实上（可能）不可能。
- 不可能原因（一）：我们没有所有的 X 和 y 的组合。
- 不可能原因（二）：$f_0 \notin \mathcal{F}$。
- 不可能原因（三）：我们求解 $\hat{f}$ 时候有困难。
- 但是基本启示是：我们要找到一个足够大的 $\mathcal{F}$ 使他包含 f_0, 并且这个 $\mathcal{F}$ 应该足够小使得求解比较容易 $\rightarrow$ 自相矛盾。

随机的世界

- 本质上来说，世界上是随机的
- 随机的来源：
  - 缺乏信息 → 最主要问题，在表格化数据中最为明显
  - 测量误差 → 大部分信息都有误差
    - 比如说年龄 800 岁，收入 400 万亿
  - 模型误差 → 假设模型形式和现实的差别
  - 估计误差 → 得到模型过程中造成的误差
  - 优化误差 → 求解过程中的误差
  - 评估误差 → 评估本身也存在误差

缺乏信息和过拟合问题

极客大学

- 假设目标是用身高预测体重
- 为什么不可以进行插值？

请思考

根本原因

- 缺乏信息：人有胖有瘦，仅仅给定身高，不可能判断
- 导致结果；如果要求身高必须解释体重，身高就承担了非理性的要求
- 相关结果：variance 较大
- 统计学根本区别于函数逼近的原因。
  - 函数逼近：$y = f_0(X)$。
  - 统计学 $y = f_0(X) + \epsilon$。

Bias 和 Variance

- Bias：话说得很详细，但是很不准
    - 北京明天下午两点四十分会发生里氏 2.6 级地震
- Variance：含糊其词，但是很准
    - 在这个世界上有一天会发生地震
- 往往存在 Bias 和 Variance 的权衡（**但这不是全部，它本身的数学理论只是针对回归的**）
- Bias 大：过拟合
- Variance 大：欠拟合

测量误差

- 往往难以处理
- 是数据预处理一个重要部分

模型假设

- 假设背景：存在一个上帝知道的真实的模型，但他不知道部分误差，所以模型一定会有**损失**
  - 但就该**损失函数而言**，这个真实的模型一定是预测最好的
- 现实情况：因为不知道真实的模型，所以只能采用一些模型来逼近
  - 一般情况下不知道真实模型，只能选择一般的模型 → 估计方差大

估计误差

- 即使对于同样的模型或问题，也有不同办法得到模型的参数
  - 极大似然估计和贝叶斯估计
  - 增强学习中的 Q-learning 和 Policy Gradient
- 好的方法可以减少其中误差

估计问题

极客大学

- 求解的过程，就是迭代的过程
- 迭代是否会收敛是一个很大的问题
- 在神经网络中尤其明显，但在传统模型中也存在

评估问题

- 因为不知道真实的损失函数（除非有无限多的测试样本），所以必须评估
- 评估的越多，训练样本就越少 → 出现了交叉验证的概念
- 注意避免**不公平的评估**

评估误区

极客大学

- 只用训练集 → 不公平
- 无数次的测试训练集 → 不可以（否则猜就可以了）
- 建模数据和实际场景不同：在 2019 年建模预测 2020 年上半年旅游业情况

评估误区

- **重要原则：一定要看评估本身的误差多大，然后决定做法是否有提升**
- 重要提示：
  - 越是误差小的领域，需要概率角度越多
  - 误差大的领域，概率角度可能不能帮上太多忙，更应该找可以优化的地方

理论的例外：预训练的存在

- 从概率理论上来说，预训练不应该有任何帮助：预训练和当前任务无关（?），而且模型表达力没有变
- 预训练是深度学习最重要发明之一
  - 例子：从一个字预测出词语和预测情感没关系
  - 现实：预测词语表示了对语义的理解，所以对预测情感有帮助
  - 从优化的角度来说：有利于优化

这不是全部的角度

极客大学

- 很多问题要 case-by-case 分析
- 重点：**从不同角度出发**（数学思维）
- 从不同角度看同一个问题：其他角度的进展可以帮助另外借用不同的想法

大纲

1. 怎样学数学
2. 机器学习的各种角度和建模流程
3. 概率论和统计学复习
4. 极大似然估计
5. 贝叶斯公式和变分贝叶斯

概率论简介

- 概率论是描述随机的语言
- 概率论分为朴素概率论和公理性概率论
- 主要讲朴素概率论

最简单情况：一维离散

- 一维离散意味着可以直接讨论概率
- 一维离散意味着可以假设概率取值只是整数
- 例子：男 =1，女 =2，未知 =3
  - $P(X < 3) = \dots$
  - $p(X = 1) = \dots.$
  - $P(X \leq x) = \sum_{i \leq x} p(X = i)$, 或者用更标准的写法 $P(X \leq t) = \sum_{x \leq t} p(x)$

连续变量

- 连续意味着可能性至少不是有限的
- 还是可以定义 $P(X \leq x)$
- 但是定义 $p(x)$ 的时候就有问题了

思考：为什么？

PDF 和 CDF

极客大学

- 在给定一个连续变量时，只能定义 $P(X \leq x) = \int_{-\infty}^{x} p(x)dx$
- 虽然离散和连续的定义有所不同，但是积分本身就是一种非常复杂的加法
- $F_X(t) := P(X \leq t)$ 就是所谓的概率 Cumulative Distribution Function
- $p(x)$ 就是所谓的 Probability Density Function，不是概率值

多维情况

- 以二维为例：$P(X \leq x, Y \leq y) = \int_{-\infty}^{x} \int_{-\infty}^{y} p(x, y) dxdy$
- 对于边际分布 $p(x) = \int p(x, y) dy$
- 条件概率 $p(x|y) = p(x, y) / p(y)$

练习：手推贝叶斯公式

极客大学

$$p(y|x) = \frac{p(y)p(x|y)}{\int p(x|y)p(y)\,dy}$$

重点关注

- Multinomial：$P(X = x_i) = p_i$
- 正态分布：$p(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$，其中 μ 是 σ 是参数
- 其它常见的概率分布可以参见Shao (2003)

大纲

极客大学

1 怎样学数学

2 机器学习的各种角度和建模流程

3 概率论和统计学复习

4 极大似然估计
- 极大似然估计基本思路
- （可选）EM 算法和 HMM

5 贝叶斯公式和变分贝叶斯

大纲

极客大学

1. 怎样学数学
2. 机器学习的各种角度和建模流程
3. 概率论和统计学复习
4. 极大似然估计
   - 极大似然估计基本思路
   - （可选）EM 算法和 HMM
5. 贝叶斯公式和变分贝叶斯

极大似然估计：例子

- 我们考虑最简单的情况，即掷一个不公平的硬币。
- 每一个硬币向上的概率为 $p(x_i)$；我们用 $y_i = 1$ 记载硬币向上。
- 就此得到硬币向下的概率为 $1 - p(x_i)$，用 $y_i = 0$ 表示。
- 整体观测到目前情况的概率为 $p(x_i)^{y_i} \times (1 - p(x_i))^{(1-y_i)}$。这个函数为所谓的**似然函数**。
- 这个形式比较难看，我们不妨取个 $\log$。那就是 $y_i \log(p(x_i)) + (1 - y_i)\log(1 - p(x_i))$。
- 这个玩意，**就是所谓的对数似然函数**。

思考：什么是好的 p

- 如果我们知道 p，那什么都不用做。
- 问题不知道。但是什么是好的 p 呢？
- 假设只抛一次硬币：
  - 一个估计 p 的似然函数为 0.3。
  - 另一个估计 p 的似然函数为 0.9。
- 哪个更好？

极大似然函数的基本思想

- 找到使目前似然函数最大的那个观测。
- 或者由于对数变换是单调变化，找到负的对数似然函数最小的那个。

继续抛硬币...

- 只抛一次硬币，当然没有任何做推断的价值。
- 现在假设我们抛 N 次硬币，得到观测 $\{x_i, y_i; i \le N\}$。
- 继续假定每次抛硬币的不影响下一次抛硬币的**概率分布**，即观测独立。
- 则似然函数为 $\prod_i p(x_i)^{y_i}(1-p(x_i))^{(1-y_i)}$。
- 这个连乘会有很大问题：因为如果我们乘一个 0 到 1 之间的数，得到的乘积会越来越小；特别小的时候，电脑就会出现数值问题（比如说 10 的负十万次方）。

如何解决数值问题

- 取个 $\log$ 即可。别忘了 $\log(xy) = \log(x) + \log(y)$。
- 则负的对数似然函数为：
  $-\sum_i (y_i \log(p(x_i)) + (1 - y_i)\log(1 - p(x_i)))$。
- 看着眼熟不？这个就是 Binary Cross Entropy。

但是还有个问题...

- $p(x_i)$ 长什么样呢？
- 起码我们要控制 $p(x_i)$ 取值在 0 到 1 之间。
- 一个常见选择 $p(x_i) = \frac{1}{1+\exp(-f(x_i))}$ 。
- 如果 $f(x_i) = \sum_k \beta_k x_i$, 其中 β_k 为未知参数（需要求解），则我们得到了所谓逻辑回归的数学表达形式。
- 注意：这种 f 的函数形式被称之为线性函数；近似于多个线性函数组合的函数是最重要的一类函数形式。

另外一个常见的情况...

极客大学

- 现在假设我们有 y_i，服从期望为 $f(x_i)$ 且方差为 1 的正态分布。
- 这也就是说 $p(y_i) = \frac{1}{\sqrt{2\pi}}\exp(-(y_i - f(x_i))^2/2)$。
- 让我们来共同推导他的对数似然函数！

5 分钟自己推导时间...

推导

我们需要的负的对数似然函数等于

$$-\sum_i \log p(x_i) = -\sum_i (-(y_i - f(x_i))^2)/2 + K$$

其中 K 是一个跟 f 没关系的常数。换句话说，我们最小化的距离是 $\sum_i (y_i - f(x_i))^2$，这就是**最小二乘法**。

分类和回归

极客大学

- 第一种情况，称之为二分类分类问题。对应多分类问题也可以进行对应推导。
- 第二种情况，称之为回归问题。
- 大部分机器学习工程师假设世界上只存在这两种问题。但是事实上，其他问题多的很（即使在监督学习框架下）。

某银行小微快贷额度测算问题

- 目标：小企业贷款额度确定。
- 考虑方向：
  - 违规可能性。一般要控制风险在一定范围内。
  - 需求。对贷款需求越高的企业应该给更多贷款。
- 第一个问题可以作为分类问题解决。
- 第二个问题不好解决。

基本思想

- 我们观测不到企业的真实需求。但我们可以假设存在一个真实需求。
- 我们知道实际放款额和实际使用金额。所以存在两种情况。
  - 放款额度大于实际使用金额。这时我们可以假定实际需求极为实际使用金额。
  - 放宽额度等于实际使用金额。这时候我们不知道实际需求，但是我们知道实际需求一定大于等于放款额度。

模型的基本思路

极客大学

- 假设真实需求为 y_i^*
- 进一步假设 $y_i^* = f(x_i) + \epsilon_i$，且 ϵ_i 为正态分布。
- 当发生截断时，其似然函数为 $P(y_i^* \geq y_i)$.
- 当不发生截断时，其似然函数为 $p(y_i)$.
- 两者结合，即可以得到估计方式。
- 如此简单的一个思路，居然难住了当时在场的全部厂商（包括所有顶尖咨询公司和所有顶尖大厂）。全部厂商均想把这个问题变成回归或分类问题。
- 我们在下周将会回到这个课题。

大纲

1 怎样学数学

2 机器学习的各种角度和建模流程

3 概率论和统计学复习

4 极大似然估计
- 极大似然估计基本思路
- （可选）EM 算法和 HMM

5 贝叶斯公式和变分贝叶斯

本节目的

- 在极大似然框架中，大部分时候如果容易推导出对数似然函数的话，那么求解将会非常容易。
- 但是如果存在隐变量，则推导变得非常困难。
- 在一些情况下，EM 算法是解决隐变量问题的一个非常通用的框架。
- 然而在现实中，这种情况很少出现。
- 但是偏偏在面试部分大厂很喜欢难为学生并要求推导 HMM 的估计方式。

HMM 算法的推导难度

极客大学

- HMM 算法的估计方法称之为 Baum-Welch 算法。
- 换句话说，这是两个数学家折腾好几年折腾出来的东西。
- 即使知道 HMM 的推导思路，我个人在复现的时候也至少推导了三次，花了一天时间。并且中间还参考了各种讲义。
- 如果我完全不知道推导思路，仅仅知道该算法是可以推导的，我最少也得花一个月时间才能搞清楚（保守估计）。
- 相比之下，当我知道 Axiom Of Choice 等价于 Zorn's Lemma 时候，我只用了三天时间就推导出来。

换句话说…

极客大学

- 现场去“推导”该算法是不可能的。
- 现场去“默写”该算法是有可能的。
- 默写跟数学能力毫无关系。
- 一些面试官喜欢考这道题的缘故要么是**不想招人**，要么就是**自己没有做过数学一路背下来的**。
- 我极其反感这种面试。这种面试是对**面试者和面试官的双重侮辱**。

EM 算法

极客大学

考虑以下关系。用 $l(\theta; X)$ 表示对数似然函数，则

$$
\begin{aligned}
l(\theta; X) &= \log p_\theta(X) \\
&= \log \int p_\theta(X, y) dy \\
&= \log \int \frac{p_\theta(X, y)}{p_{\tilde{\theta}}(y|X)} p_{\tilde{\theta}}(y|X) dy \\
&\geq \mathrm{E}_{\tilde{\theta}}[\log p_\theta(X, Y)|X] - \mathrm{E}_{\tilde{\theta}}[\log P_{\tilde{\theta}}(y|X)|X]
\end{aligned}
$$

EM 算法

极客大学

注意在这里:

- y 是一个隐变量。
- $\tilde{\theta}$ 是当前的估计，我们的目标是通过迭代的方法找到下一步的估计 θ。换句话说，$E_{\tilde{\theta}}[\log P_{\tilde{\theta}}(y|X)|X]$ 由于跟 θ 没有关系，所以我们可以无视。
- 定义 $Q(\theta, \tilde{\theta}) = E_{\tilde{\theta}}[\log p_{\theta}(X, Y)|X]$。则 EM 算法可以定义为。
  - 计算 $Q(\theta, \tilde{\theta})$.
  - 最大化 θ。

隐马尔可夫链

极客大学

- 假设我们对于每一个观测 d 可以观测到 $\{X_t^{(d)}, 1 \leq t \leq T\}$.
- 他的概率分布取决于隐变量 $z_t^{(d)}$。并且该变量服从马尔可夫性质，换句话说，知道 $t-1$ 的信息，我们就不需要知道更早的信息，就可以得到 $z_t^{(d)}$ 的性质。
- 我们假设 X's 和 z's 都只能取有限多个值。

推导过程

我们有

$$P(z,\mathcal{X};\theta)=\prod_{d=1}^{D}\left(\pi_{z_1^{(d)}}B_{z_1^{(d)}}\left(x_1^{(d)}\right)\prod_{t=2}^{T}A_{z_{t-1}^{(d)},z_t^{(d)}}B_{z_t^{(d)}}\left(x_t^{(d)}\right)\right)$$

推导过程

对上式取 log 之后

$$\log P(z, \mathcal{X}; \theta) = \sum_{d=1}^{D} \left[\log \pi_{z_1^{(d)}} + \sum_{t=2}^{T} \log A_{z_{t-1}^{(d)} z_t^{(d)}} + \sum_{t=1}^{T} \log B_{z_t^{(d)}} \left(x_t^{(d)} \right)$$

推导过程

极客大学

扔到 Q 函数中，假设目前的参数 θ^s：

$$
\begin{aligned}
Q(\theta, \theta^s) = & \sum_{z \in \mathcal{Z}} \sum_{d=1}^{D} \log \pi_{z_1^{(d)}} P(z, \mathcal{X}; \theta^s) \\
& + \sum_{z \in \mathcal{Z}} \sum_{d=1}^{D} \sum_{t=2}^{T} \log A_{z_{t-1}^{(d)} z_t^{(d)}} P(z, \mathcal{X}; \theta^s) \\
& + \sum_{z \in \mathcal{Z}} \sum_{d=1}^{D} \sum_{t=1}^{T} \log B_{z_t^{(d)}} \left(x_t^{(d)} \right) P(z, \mathcal{X}; \theta^s)
\end{aligned}
$$

推导过程

极客大学

加上拉格朗日乘子：

$$
\begin{aligned}
\hat{L}(\theta, \theta^s) := Q(\theta, \theta^s) - \lambda_\pi \left(\sum_{i=1}^{M} \pi_i - 1 \right) \\
- \sum_{i=1}^{M} \lambda_{A_i} \left(\sum_{j=1}^{M} A_{ij} - 1 \right) \\
- \sum_{i=1}^{M} \lambda_{B_i} \left(\sum_{j=1}^{N} B_i(j) - 1 \right)
\end{aligned}
$$

推导过程

极客大学

下面让我们来首先求解 π_i。

$$
\begin{aligned}
\frac{\partial \hat{L}\left(\theta, \theta^{s}\right)}{\partial \pi_{i}} &= \frac{\partial}{\partial \pi_{i}}\left(\sum_{z \in \mathcal{Z}} \sum_{d=1}^{D} \log \pi_{z_{1}^{(d)}} P\left(z, X ; \theta^{s}\right)\right)-\lambda_{\pi}=0 \\
&= \frac{\partial}{\partial \pi_{i}}\left(\sum_{j=1}^{M} \sum_{d=1}^{D} \log \pi_{j} P\left(z_{1}^{(d)}=j, \mathcal{X} ; \theta^{s}\right)\right)-\lambda_{\pi}=0 \\
&= \sum_{d=1}^{D} \frac{P\left(z_{1}^{(d)}=i, \mathcal{X} ; \theta^{s}\right)}{\pi_{i}}-\lambda_{\pi}=0
\end{aligned}
$$

推导过程

$$\frac{\partial \hat{L}\left(\theta, \theta^{s}\right)}{\partial \lambda_{\pi}} = -\left(\sum_{i=1}^{M} \pi_{i} - 1\right) = 0$$

推导过程

求解，我们可以得到

$$
\begin{aligned}
\pi_i &= \frac{\sum_{d=1}^{D} P\left(z_1^{(d)} = i, \mathcal{X}; \theta^s\right)}{\sum_{j=1}^{M}\sum_{d=1}^{D} P\left(z_1^{(d)} = j, \mathcal{X}; \theta^s\right)} = \frac{\sum_{d=1}^{D} P\left(z_1^{(d)} = i, \mathcal{X}; \theta^s\right)}{\sum_{d=1}^{D}\sum_{j=1}^{M} P\left(z_1^{(d)} = j, \mathcal{X}; \theta^s\right)} \\
&= \frac{\sum_{d=1}^{D} P\left(z_1^{(d)} = i, \mathcal{X}; \theta^s\right)}{\sum_{d=1}^{D} P\left(\mathcal{X}; \theta^s\right)} = \frac{\sum_{d=1}^{D} P\left(z_1^{(d)} = i, \mathcal{X}; \theta^s\right)}{DP\left(\mathcal{X}; \theta^s\right)} \\
&= \frac{\sum_{d=1}^{D} P\left(\mathcal{X}; \theta^s\right) P\left(z_1^{(d)} = i \mid \mathcal{X}; \theta^s\right)}{DP\left(\mathcal{X}; \theta^s\right)} = \frac{1}{D}\sum_{d=1}^{D} P\left(z_1^{(d)} = i \mid \mathcal{X}; \theta^s\right) \\
&= \frac{1}{D}\sum_{d=1}^{D} P\left(z_1^{(d)} = i \mid X^{(d)}; \theta^s\right)
\end{aligned}
$$

推导过程

采用类似方法:

$$
\begin{aligned}
A_{ij} &= \frac{\sum_{d=1}^{D}\sum_{t=2}^{T} P\left(z_{t-1}^{(d)}=i, z_t^{(d)}=j, \mathcal{X}; \theta^s\right)}{\sum_{j=1}^{M}\sum_{d=1}^{D}\sum_{t=2}^{T} P\left(z_{t-1}^{(d)}=i, z_t^{(d)}=j, \mathcal{X}; \theta^s\right)} \\
&= \frac{\sum_{d=1}^{D}\sum_{t=2}^{T} P\left(z_{t-1}^{(d)}=i, z_t^{(d)}=j, \mathcal{X}; \theta^s\right)}{\sum_{d=1}^{D}\sum_{t=2}^{T} P\left(z_{t-1}^{(d)}=i, \mathcal{X}; \theta^s\right)} \\
&= \frac{\sum_{d=1}^{D}\sum_{t=2}^{T} P(\mathcal{X}; \theta^s)\, P\left(z_{t-1}^{(d)}=i, z_t^{(d)}=j \mid \mathcal{X}; \theta^s\right)}{\sum_{d=1}^{D}\sum_{t=2}^{T} P(\mathcal{X}; \theta^s)\, P\left(z_{t-1}^{(d)}=i \mid \mathcal{X}; \theta^s\right)} \\
&= \frac{\sum_{d=1}^{D}\sum_{t=2}^{T} P\left(z_{t-1}^{(d)}=i, z_t^{(d)}=j \mid X^{(d)}; \theta^s\right)}{\sum_{d=1}^{D}\sum_{t=2}^{T} P\left(z_{t-1}^{(d)}=i \mid X^{(d)}; \theta^s\right)}
\end{aligned}
$$

继续我们有...

极客大学

$$
\begin{aligned}
B_i(j) &= \frac{\sum_{d=1}^{D} \sum_{t=1}^{T} P\left(z_t^{(d)} = i, \mathcal{X}; \theta^s\right) I\left(x_t^{(d)} = j\right)}{\sum_{j=1}^{N} \sum_{d=1}^{D} \sum_{t=1}^{T} P\left(z_t^{(d)} = i, \mathcal{X}; \theta^s\right) I\left(x_t^{(d)} = j\right)} \\
&= \frac{\sum_{d=1}^{D} \sum_{t=1}^{T} P\left(z_t^{(d)} = i, \mathcal{X}; \theta^s\right) I\left(x_t^{(d)} = j\right)}{\sum_{d=1}^{D} \sum_{t=1}^{T} P\left(z_t^{(d)} = i, \mathcal{X}; \theta^s\right)} \\
&= \frac{\sum_{d=1}^{D} \sum_{t=1}^{T} P\left(z_t^{(d)} = i \mid X^{(d)}; \theta^s\right) I\left(x_t^{(d)} = j\right)}{\sum_{d=1}^{D} \sum_{t=1}^{T} P\left(z_t^{(d)} = i \mid X^{(d)}; \theta^s\right)}
\end{aligned}
$$

这道题还没完...

- 我们为什么要推导 $P\left(z_{t-1}^{(d)}=i, z_t^{(d)}=j \mid X^{(d)}; \theta^s\right)$ 和 $P\left(z_t^{(d)}=i \mid X^{(d)}; \theta^s\right)$。
- 这是因为这两者可以用动态规划很容易求解。
- 细节作为（可选）练习题。

这道题难在哪里？

极客大学

- $P\left(z_{t-1}^{(d)}=i, z_t^{(d)}=j \mid X^{(d)}; \theta^s\right)$ 和 $P\left(z_t^{(d)}=i \mid X^{(d)}; \theta^s\right)$ 可以动态求解有效动态求解这件事情不可能一眼看出来。甚至我们在开始推导的时候也不可能考虑到动态求解的问题。
- 在这个推导过程中，如果不知道我们目标是推出这两个量的表达式，则我们在几百个可能性当中可能会折腾很久。
- 如果知道，当然这也不容易。但是起码这道题在一天内还是有可能做出来的（也有可能很快做出来）。
- 所以如果仅仅从推导过程来看，推导过程并不长。但是假如某个“业界大牛”告诉你他手推了一个小时就“推导”出来了，那他大概是把“推导”跟“默写”搞错了。

大纲

极客大学

1. 怎样学数学
2. 机器学习的各种角度和建模流程
3. 概率论和统计学复习
4. 极大似然估计
5. 贝叶斯公式和变分贝叶斯