极客大学

极客大学机器学习训练营
机器学习基本概念

王然

众微科技 AI Lab 负责人

二〇二一年一月九日

大纲

极客大学

1. 怎样学数学
2. 机器学习的各种角度和建模流程
3. 概率论和统计学复习
4. 极大似然估计
5. 贝叶斯估计和变分贝叶斯
6. 矩阵和张量求导

大纲

极客大学

1. 怎样学数学
2. 机器学习的各种角度和建模流程
3. 概率论和统计学复习
4. 极大似然估计
5. 贝叶斯估计和变分贝叶斯
6. 矩阵和张量求导

为什么要学数学

极客大学

- AI 的语言 $\rightarrow$ 不理解数学，不可能理解模型
- 创新的根基 $\rightarrow$ 看起来创新不多，但是实际上有很多地方可以创新，而且创新没有那么难
- 数学锻炼思维

数学的两种学法

极客大学

- 把数学当做语言：不管它的意思，严格按照要求 → 我们主要讲方法
- 数学真正的学法，是以证明为目的的

数学真正的思考方式

极客大学

核心：

- Frame and Hypotheses
- Elements and Relationships
- Patterns
- Intuition
- Retrospect and Empathetic
- Bucket(In/Out/New)
- Strategic minds

数学理论的主要内容

极客大学

- 机器学习的各种角度和建模流程
- 概率论和统计学基础概念复习
- 极大似然体系和 EM 算法
- 贝叶斯体系和 Variational Bayes 算法
- 矩阵代数：基本概念复习和 Tensor 求导

大纲

极客大学

1. 怎样学数学
2. 机器学习的各种角度和建模流程
3. 概率论和统计学复习
4. 极大似然估计
5. 贝叶斯估计和变分贝叶斯
6. 矩阵和张量求导

为什么要掌握各种角度

- 最终目的：效果好，即准确性高
- 为了达到最终目的，必须从不同角度考虑

函数逼近的视角

极客大学

- 最简单的是视角.
- 目标：给定 X 预测 y.
- 假设：存在真实的 $y = f_0(X)$.
- 如果我们知道 f_0，那么我们不需要做任工作。
- 但是我们不知道。

函数逼近的视角

- 相比之下，我们观测 $\{X_i, y_i; i \in \mathfrak{I}\}$.
- 我们可以假设 $f \in \mathcal{F}$.
- 目标：给定一个损失函数 c, 最小化 $\sum_i c(f(X_i), y_i)$.
- 这个估计我们称之为 $\hat{f}$.

什么样的 $\hat{f}$ 是好的

极客大学

- 最理想状况 $\hat{f} = f_0$；事实上（可能）不可能。
- 不可能原因（一）：我们没有所有的 X 和 y 的组合。
- 不可能原因（二）：$f_0 \notin \mathcal{F}$。
- 不可能原因（三）：我们求解 $\hat{f}$ 时候有困难。
- 但是基本启示是：我们要找到一个足够大的 $\mathcal{F}$ 使他包含 f_0，并且这个 $\mathcal{F}$ 应该足够小使得求解比较容易 $\rightarrow$ 自相矛盾。

随机的世界

极客大学

- 本质上来说，世界上是随机的
- 随机的来源：
  - 缺乏信息 → 最主要问题，在表格化数据中最为明显
  - 测量误差 → 大部分信息都有误差
    - 比如说年龄 800 岁，收入 400 万亿
  - 模型误差 → 假设模型形式和现实的差别
  - 估计误差 → 得到模型过程中造成的误差
  - 优化误差 → 求解过程中的误差
  - 评估误差 → 评估本身也存在误差

缺乏信息和过拟合问题

- 假设目标是用身高预测体重
- 为什么不可以进行插值？

请思考

根本原因

- 缺乏信息：人有胖有瘦，仅仅给定身高，不可能判断
- 导致结果；如果要求身高必须解释体重，身高就承担了非理性的要求
- 相关结果：variance 较大
- 统计学根本区别于函数逼近的原因。
  - 函数逼近：$y = f_0(X)$。
  - 统计学 $y = f_0(X) + \epsilon$。

Bias 和 Variance

极客大学

- Bias：话说得很详细，但是很不准
  - 北京明天下午两点四十分会发生里氏 2.6 级地震
- Variance：含糊其词，但是很准
  - 在这个世界上有一天会发生地震
- 往往存在 Bias 和 Variance 的权衡（**但这不是全部，它本身的数学理论只是针对回归的**）
- Bias 大：过拟合
- Variance 大：欠拟合

测量误差

- 往往难以处理
- 是数据预处理一个重要部分

模型假设

- 假设背景：存在一个上帝知道的真实的模型，但他不知道部分误差，所以模型一定会有**损失**
  - 但就该**损失函数而言**，这个真实的模型一定是预测最好的
- 现实情况：因为不知道真实的模型，所以只能采用一些模型来逼近
  - 一般情况下不知道真实模型，只能选择一般的模型 $\rightarrow$ 估计方差大

估计误差

- 即使对于同样的模型或问题，也有不同办法得到模型的参数
  - 极大似然估计和贝叶斯估计
  - 增强学习中的 Q-learning 和 Policy Gradient
- 好的方法可以减少其中误差

估计问题

- 求解的过程，就是迭代的过程
- 迭代是否会收敛是一个很大的问题
- 在神经网络中尤其明显，但在传统模型中也存在

评估问题

- 因为不知道真实的损失函数（除非有无限多的测试样本），所以必须评估
- 评估的越多，训练样本就越少 $\rightarrow$ 出现了交叉验证的概念
- 注意避免**不公平的评估**

评估误区

- 只用训练集 $\rightarrow$ 不公平
- 无数次的测试训练集 $\rightarrow$ 不可以（否则猜就可以了）
- 建模数据和实际场景不同：在 2019 年建模预测 2020 年上半年旅游业情况

评估误区

- **重要原则：一定要看评估本身的误差多大，然后决定做法是否有提升**
- 重要提示：
  - 越是误差小的领域，需要概率角度越多
  - 误差大的领域，概率角度可能不能帮上太多忙，更应该找可以优化的地方

理论的例外：预训练的存在

- 从概率理论上来说，预训练不应该有任何帮助：预训练和当前任务无关(?)，而且模型表达力没有变
- 预训练是深度学习最重要发明之一
  - 例子：从一个字预测出词语和预测情感没关系
  - 现实：预测词语表示了对语义的理解，所以对预测情感有帮助
  - 从优化的角度来说：有利于优化

这不是全部的角度

极客大学

- 很多问题要 case-by-case 分析
- 重点：**从不同角度出发**（数学思维）
- 从不同角度看同一个问题：其他角度的进展可以帮助另外借用不同的想法

大纲

极客大学

1. 怎样学数学
2. 机器学习的各种角度和建模流程
3. 概率论和统计学复习
4. 极大似然估计
5. 贝叶斯估计和变分贝叶斯
6. 矩阵和张量求导

概率论简介

极客大学

- 概率论是描述随机的语言
- 概率论分为朴素概率论和公理性概率论
- 主要讲朴素概率论

最简单情况：一维离散

- 一维离散意味着可以直接讨论概率
- 一维离散意味着可以假设概率取值只是整数
- 例子：男 $=1$，女 $=2$，未知 $=3$
  - $P(X < 3) = \ldots$
  - $p(X = 1) = \ldots$.
  - $P(X \leq x) = \sum_{i \leq x} p(X = i)$, 或者用更标准的写法 $P(X \leq t) = \sum_{x \leq t} p(x)$

连续变量

- 连续意味着可能性至少不是有限的
- 还是可以定义 $P(X \leq x)$
- 但是定义 $p(x)$ 的时候就有问题了

思考：为什么？

PDF 和 CDF

- 在给定一个连续变量时，只能定义 $P(X \leq x) = \int_{-\infty}^{x} p(x)dx$
- 虽然离散和连续的定义有所不同，但是积分本身就是一种非常复杂的加法
- $F_X(t) := P(X \leq t)$ 就是所谓的概率 Cumulative Distribution Function
- $p(x)$ 就是所谓的 Probability Density Function，不是概率值

多维情况

- 以二维为例：$P(X \leq x, Y \leq y) = \int_{-\infty}^{x} \int_{-\infty}^{y} p(x, y) dxdy$
- 对于边际分布 $p(x) = \int p(x, y) dy$
- 条件概率 $p(x|y) = p(x, y)/p(y)$

练习：手推贝叶斯公式

$$p(y|x) = \frac{p(y)p(x|y)}{\int p(x|y)p(y)dy}$$

重点关注

- Multinomial：$P(X = x_i) = p_i$
- 正态分布：$p(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$，其中 μ 是 σ 是参数
- 其它常见的概率分布可以参见Shao (2003)

大纲

极客大学

1. 怎样学数学
2. 机器学习的各种角度和建模流程
3. 概率论和统计学复习
4. 极大似然估计
   - 极大似然估计基本思路
   - （可选）EM 算法和 HMM
5. 贝叶斯估计和变分贝叶斯
6. 矩阵和张量求导

大纲

极客大学

1. 怎样学数学
2. 机器学习的各种角度和建模流程
3. 概率论和统计学复习
4. 极大似然估计
   - 极大似然估计基本思路
   - （可选）EM 算法和 HMM
5. 贝叶斯估计和变分贝叶斯
6. 矩阵和张量求导

极大似然估计：例子

- 我们考虑最简单的情况，即掷一个不公平的硬币。
- 每一个硬币向上的概率为 $p(x_i)$；我们用 $y_i = 1$ 记载硬币向上。
- 就此得到硬币向下的概率为 $1 - p(x_i)$，用 $y_i = 0$ 表示。
- 整体观测到目前情况的概率为 $p(x_i)^{y_i} \times (1 - p(x_i))^{(1-y_i)}$。这个函数为所谓的**似然函数**。
- 这个形式比较难看，我们不妨取个 $\log$。那就是 $y_i \log(p(x_i)) + (1 - y_i) \log(1 - p(x_i))$。
- 这个玩意，**就是所谓的对数似然函数**。

思考：什么是好的 p

- 如果我们知道 p，那什么都不用做。
- 问题不知道。但是什么是好的 p 呢？
- 假设只抛一次硬币：
  - 一个估计 p 的似然函数为 0.3。
  - 另一个估计 p 的似然函数为 0.9。
- 哪个更好？

极大似然函数的基本思想

- 找到使目前似然函数最大的那个观测。
- 或者由于对数变换是单调变化，找到负的对数似然函数最小的那个。

继续抛硬币...

- 只抛一次硬币，当然没有任何做推断的价值。
- 现在假设我们抛 N 次硬币，得到观测 $\{x_i, y_i; i \leq N\}$。
- 继续假定每次抛硬币的不影响下一次抛硬币的**概率分布**，即观测独立。
- 则似然函数为 $\prod_i p(x_i)^{y_i}(1 - p(x_i))^{(1-y_i)}$。
- 这个连乘会有很大问题：因为如果我们乘一个 0 到 1 之间的数，得到的乘积会越来越小；特别小的时候，电脑就会出现数值问题（比如说 10 的负十万次方）。

如何解决数值问题

- 取个 $\log$ 即可。别忘了 $\log(xy) = \log(x) + \log(y)$。
- 则负的对数似然函数为：$-\sum_i (y_i \log(p(x_i)) + (1 - y_i) \log(1 - p(x_i)))$。
- 看着眼熟不？这个就是 Binary Cross Entropy。

但是还有个问题...

- $p(x_i)$ 长什么样呢？
- 起码我们要控制 $p(x_i)$ 取值在 0 到 1 之间。
- 一个常见选择 $p(x_i) = \frac{1}{1+\exp(-f(x_i))}$ 。
- 如果 $f(x_i) = \sum_k \beta_k x_i$, 其中 β_k 为未知参数（需要求解），则我们得到了所谓逻辑回归的数学表达形式。
- 注意：这种 f 的函数形式被称之为线性函数；近似于多个线性函数组合的函数是最重要的一类函数形式。

另外一个常见的情况...

极客大学

- 现在假设我们有 y_i，服从期望为 $f(x_i)$ 且方差为 1 的正态分布。
- 这也就是说 $p(y_i) = \frac{1}{\sqrt{2\pi}} \exp(-(y_i - f(x_i)^2/2)$。
- 让我们来共同推导他的对数似然函数！

5 分钟自己推导时间...

推导

我们需要的负的对数似然函数等于

$$-\sum_i \log p(x_i) = -\sum_i (-(y_i - f(x_i))^2)/2 + K$$

其中 K 是一个跟 f 没关系的常数。换句话说，我们最小化的距离是 $\sum_i (y_i - f(x_i))^2$，这就是**最小二乘法**。

分类和回归

- 第一种情况，称之为二分类分类问题。对应多分类问题也可以进行对应推导。
- 第二种情况，称之为回归问题。
- 大部分机器学习工程师假设世界上只存在这两种问题。但是事实上，其他问题多的很（即使在监督学习框架下）。

某银行小微快贷额度测算问题

极客大学

- 目标：小企业贷款额度确定。
- 考虑方向：
  - 违规可能性。一般要控制风险在一定范围内。
  - 需求。对贷款需求越高的企业应该给更多贷款。
- 第一个问题可以作为分类问题解决。
- 第二个问题不好解决。

基本思想

- 我们观测不到企业的真实需求。但我们可以假设存在一个真实需求。
- 我们知道实际放款额和实际使用金额。所以存在两种情况。
  - 放款额度大于实际使用金额。这时我们可以假定实际需求极为实际使用金额。
  - 放宽额度等于实际使用金额。这时候我们不知道实际需求，但是我们知道实际需求一定大于等于放款额度。

模型的基本思路

- 假设真实需求为 y_i^*
- 进一步假设 $y_i^* = f(x_i) + \epsilon_i$，且 ϵ_i 为正态分布。
- 当发生截断时，其似然函数为 $P(y_i^* \geq y_i)$.
- 当不发生截断时，其似然函数为 $p(y_i)$.
- 两者结合，即可以得到估计方式。
- 如此简单的一个思路，居然难住了当时在场的全部厂商（包括所有顶尖咨询公司和所有顶尖大厂）。全部厂商均想把这个问题变成回归或分类问题。
- 我们在下周将会回到这个课题。

大纲

极客大学

1. 怎样学数学
2. 机器学习的各种角度和建模流程
3. 概率论和统计学复习
4. 极大似然估计
   - 极大似然估计基本思路
   - （可选）EM 算法和 HMM
5. 贝叶斯估计和变分贝叶斯
6. 矩阵和张量求导

本节目的

极客大学

- 在极大似然框架中，大部分时候如果容易推导出对数似然函数的话，那么求解将会非常容易。
- 但是如果存在隐变量，则推导变得非常困难。
- 在一些情况下，EM 算法是解决隐变量问题的一个非常通用的框架。
- 然而在现实中，这种情况很少出现。
- 但是偏偏在面试部分大厂很喜欢难为学生并要求推导 HMM 的估计方式。

HMM 算法的推导难度

极客大学

- HMM 算法的估计方法称之为 Baum-Welch 算法。
- 换句话说，这是两个数学家折腾好几年折腾出来的东西。
- 即使知道 HMM 的推导思路，我个人在复现的时候也至少推导了三次，花了一天时间。并且中间还参考了各种讲义。
- 如果我完全不知道推导思路，仅仅知道该算法是可以推导的，我最少也得花一个月时间才能搞清楚（保守估计）。
- 相比之下，当我知道 Axiom Of Choice 等价于 Zorn's Lemma 时候，我只用了三天时间就推导出来。

换句话说...

极客大学

- 现场去“推导”该算法是不可能的。
- 现场去“默写”该算法是有可能的。
- 默写跟数学能力毫无关系。
- 一些面试官喜欢考这道题的缘故要么是**不想招人**，要么就是**自己没有做过数学一路背下来的**。
- 我极其反感这种面试。这种面试是对**面试者和面试官的双重侮辱**。

考虑以下关系。用 $l(\theta; X)$ 表示对数似然函数，则

$$
\begin{aligned}
l(\theta; X) &= \log p_\theta(X) \\
&= \log \int p_\theta(X, y) dy \\
&= \log \int \frac{p_\theta(X, y)}{p_{\tilde{\theta}}(y|X)} p_{\tilde{\theta}}(y|X) dy \\
&\geq \mathrm{E}_{\tilde{\theta}}[\log p_\theta(X, Y)|X] - \mathrm{E}_{\tilde{\theta}}[\log P_{\tilde{\theta}}(y|X)|X]
\end{aligned}
$$

EM 算法

注意在这里：

- y 是一个隐变量。
- $\tilde{\theta}$ 是当前的估计，我们的目标是通过迭代的方法找到下一步的估计 θ。换句话说，$\mathrm{E}_{\tilde{\theta}}[\log P_{\tilde{\theta}}(y|X)|X]$ 由于跟 θ 没有关系，所以我们可以无视。
- 定义 $Q(\theta, \tilde{\theta}) = \mathrm{E}_{\tilde{\theta}}[\log p_{\theta}(X, Y)|X]$。则 EM 算法可以定义为。
  - 计算 $Q(\theta, \tilde{\theta})$.
  - 最大化 θ。

隐马尔可夫链

- 假设我们对于每一个观测 d 可以观测到 $\{X_t^{(d)}, 1 \leq t \leq T\}$.
- 他的概率分布取决于隐变量 $z_t^{(d)}$。并且该变量服从马尔可夫性质，换句话说，知道 $t-1$ 的信息，我们就不需要知道更早的信息，就可以得到 $z_t^{(d)}$ 的性质。
- 我们假设 X's 和 z's 都只能取有限多个值。

推导过程

我们有

$$P(z, \mathcal{X}; \theta) = \prod_{d=1}^{D} \left(\pi_{z_1^{(d)}} B_{z_1^{(d)}} \left(x_1^{(d)} \right) \prod_{t=2}^{T} A_{z_{t-1}^{(d)} z_t^{(d)}} B_{z_t^{(d)}} \left(x_t^{(d)} \right) \right)$$

推导过程

对上式取 log 之后

$$\log P(z, \mathcal{X}; \theta) = \sum_{d=1}^{D} [\log \pi_{z_1^{(d)}} + \sum_{t=2}^{T} \log A_{z_{t-1}^{(d)} z_t^{(d)}} + \sum_{t=1}^{T} \log B_{z_t^{(d)}} \left(x_t^{(d)} \right)]$$

推导过程

扔到 Q 函数中，假设目前的参数 θ^s：

$$
\begin{aligned}
Q(\theta, \theta^s) = & \sum_{z \in \mathcal{Z}} \sum_{d=1}^{D} \log \pi_{z_1^{(d)}} P(z, \mathcal{X}; \theta^s) \\
& + \sum_{z \in \mathcal{Z}} \sum_{d=1}^{D} \sum_{t=2}^{T} \log A_{z_{t-1}^{(d)} z_t^{(d)}} P(z, \mathcal{X}; \theta^s) \\
& + \sum_{z \in \mathcal{Z}} \sum_{d=1}^{D} \sum_{t=1}^{T} \log B_{z_t^{(d)}} \left(x_t^{(d)} \right) P(z, \mathcal{X}; \theta^s)
\end{aligned}
$$

推导过程

加上拉格朗日乘子：

$$\hat{L}(\theta, \theta^s) := Q(\theta, \theta^s) - \lambda_\pi \left(\sum_{i=1}^{M} \pi_i - 1 \right) - \sum_{i=1}^{M} \lambda_{A_i} \left(\sum_{j=1}^{M} A_{ij} - 1 \right) - \sum_{i=1}^{M} \lambda_{B_i} \left(\sum_{j=1}^{N} B_i(j) - 1 \right)$$

推导过程

下面让我们来首先求解 π_i。

$$
\begin{aligned}
\frac{\partial \hat{L}(\theta, \theta^s)}{\partial \pi_i} &= \frac{\partial}{\partial \pi_i}\left(\sum_{z \in \mathcal{Z}} \sum_{d=1}^{D} \log \pi_{z_1^{(d)}} P(z, X; \theta^s)\right) - \lambda_\pi = 0 \\
&= \frac{\partial}{\partial \pi_i}\left(\sum_{j=1}^{M} \sum_{d=1}^{D} \log \pi_j P\left(z_1^{(d)} = j, \mathcal{X}; \theta^s\right)\right) - \lambda_\pi = 0 \\
&= \sum_{d=1}^{D} \frac{P\left(z_1^{(d)} = i, \mathcal{X}; \theta^s\right)}{\pi_i} - \lambda_\pi = 0
\end{aligned}
$$

推导过程

$$\frac{\partial \hat{L}\left(\theta, \theta^{s}\right)}{\partial \lambda_{\pi}}=-\left(\sum_{i=1}^{M} \pi_{i}-1\right)=0$$

推导过程

求解，我们可以得到

$$\pi_i = \frac{\sum_{d=1}^{D} P\left(z_1^{(d)} = i, \mathcal{X}; \theta^s\right)}{\sum_{j=1}^{M}\sum_{d=1}^{D} P\left(z_1^{(d)} = j, \mathcal{X}; \theta^s\right)} = \frac{\sum_{d=1}^{D} P\left(z_1^{(d)} = i, \mathcal{X}; \theta^s\right)}{\sum_{d=1}^{D}\sum_{j=1}^{M} P\left(z_1^{(d)} = j, \mathcal{X}; \theta^s\right)}$$

$$= \frac{\sum_{d=1}^{D} P\left(z_1^{(d)} = i, \mathcal{X}; \theta^s\right)}{\sum_{d=1}^{D} P\left(\mathcal{X}; \theta^s\right)} = \frac{\sum_{d=1}^{D} P\left(z_1^{(d)} = i, \mathcal{X}; \theta^s\right)}{DP\left(\mathcal{X}; \theta^s\right)}$$

$$= \frac{\sum_{d=1}^{D} P\left(\mathcal{X}; \theta^s\right) P\left(z_1^{(d)} = i \mid \mathcal{X}; \theta^s\right)}{DP\left(\mathcal{X}; \theta^s\right)} = \frac{1}{D}\sum_{d=1}^{D} P\left(z_1^{(d)} = i \mid \mathcal{X}; \theta^s\right)$$

$$= \frac{1}{D}\sum_{d=1}^{D} P\left(z_1^{(d)} = i \mid X^{(d)}; \theta^s\right)$$

推导过程

采用类似方法：

$$
\begin{aligned}
A_{ij} &= \frac{\sum_{d=1}^{D}\sum_{t=2}^{T} P\left(z_{t-1}^{(d)}=i, z_{t}^{(d)}=j, \mathcal{X}; \theta^{s}\right)}{\sum_{j=1}^{M}\sum_{d=1}^{D}\sum_{t=2}^{T} P\left(z_{t-1}^{(d)}=i, z_{t}^{(d)}=j, \mathcal{X}; \theta^{s}\right)} \\
&= \frac{\sum_{d=1}^{D}\sum_{t=2}^{T} P\left(z_{t-1}^{(d)}=i, z_{t}^{(d)}=j, \mathcal{X}; \theta^{s}\right)}{\sum_{d=1}^{D}\sum_{t=2}^{T} P\left(z_{t-1}^{(d)}=i, \mathcal{X}; \theta^{s}\right)} \\
&= \frac{\sum_{d=1}^{D}\sum_{t=2}^{T} P(\mathcal{X}; \theta^{s})\, P\left(z_{t-1}^{(d)}=i, z_{t}^{(d)}=j \mid \mathcal{X}; \theta^{s}\right)}{\sum_{d=1}^{D}\sum_{t=2}^{T} P(\mathcal{X}; \theta^{s})\, P\left(z_{t-1}^{(d)}=i \mid \mathcal{X}; \theta^{s}\right)} \\
&= \frac{\sum_{d=1}^{D}\sum_{t=2}^{T} P\left(z_{t-1}^{(d)}=i, z_{t}^{(d)}=j \mid X^{(d)}; \theta^{s}\right)}{\sum_{d=1}^{D}\sum_{t=2}^{T} P\left(z_{t-1}^{(d)}=i \mid X^{(d)}; \theta^{s}\right)}
\end{aligned}
$$

继续我们有...

$$
\begin{aligned}
B_i(j) &= \frac{\sum_{d=1}^{D}\sum_{t=1}^{T} P\left(z_t^{(d)} = i, \mathcal{X}; \theta^s\right) I\left(x_t^{(d)} = j\right)}{\sum_{j=1}^{N}\sum_{d=1}^{D}\sum_{t=1}^{T} P\left(z_t^{(d)} = i, \mathcal{X}; \theta^s\right) I\left(x_t^{(d)} = j\right)} \\
&= \frac{\sum_{d=1}^{D}\sum_{t=1}^{T} P\left(z_t^{(d)} = i, \mathcal{X}; \theta^s\right) I\left(x_t^{(d)} = j\right)}{\sum_{d=1}^{D}\sum_{t=1}^{T} P\left(z_t^{(d)} = i, \mathcal{X}; \theta^s\right)} \\
&= \frac{\sum_{d=1}^{D}\sum_{t=1}^{T} P\left(z_t^{(d)} = i \mid X^{(d)}; \theta^s\right) I\left(x_t^{(d)} = j\right)}{\sum_{d=1}^{D}\sum_{t=1}^{T} P\left(z_t^{(d)} = i \mid X^{(d)}; \theta^s\right)}
\end{aligned}
$$

这道题还没完...

- 我们为什么要推导 $P\left(z_{t-1}^{(d)}=i, z_t^{(d)}=j \mid X^{(d)}; \theta^s\right)$ 和 $P\left(z_t^{(d)}=i \mid X^{(d)}; \theta^s\right)$。
- 这是因为这两者可以用动态规划很容易求解。
- 细节作为（可选）练习题。

这道题难在哪里？

- $P\left(z_{t-1}^{(d)}=i, z_t^{(d)}=j \mid X^{(d)}; \theta^s\right)$ 和 $P\left(z_t^{(d)}=i \mid X^{(d)}; \theta^s\right)$ 可以动态求解有效动态求解这件事情不可能一眼看出来。甚至我们在开始推导的时候也不可能考虑到动态求解的问题。
- 在这个推导过程中，如果不知道我们目标是推出这两个量的表达式，则我们在几百个可能性当中可能会折腾很久。
- 如果知道，当然这也不容易。但是起码这道题在一天内还是有可能做出来的（也有可能很快做出来）。
- 所以如果仅仅从推导过程来看，推导过程并不长。但是假如某个“业界大牛”告诉你他手推了一个小时就“推导”出来了，那他大概是把“推导”跟“默写”搞错了。

大纲

极客大学

1. 怎样学数学
2. 机器学习的各种角度和建模流程
3. 概率论和统计学复习
4. 极大似然估计
5. 贝叶斯估计和变分贝叶斯
   - 贝叶斯估计
   - 变分贝叶斯法
6. 矩阵和张量求导

大纲

贝叶斯学派和频率学派

- 在我们之前所有的模型中，我们均假设我们有所谓的真实参数或模型，我们的目的只是推导这个真实的模型。
- 贝叶斯学派的视角不太一样：
  - 假设我们的参数是 θ，我们将会对其有一个 prior，表示为 $p(\theta)$。换句话说 θ 本身就是随机。
  - 目前我们得到了观测：X。目标是得到 posterior：$p(\theta|X)$.
- 根据贝叶斯公式我们有

$$p(\theta|X) = \frac{p(X|\theta)p(\theta)}{\int p(X|\theta)p(\theta)d\theta}$$

举例

假设 $\mu \sim N(0,1)$, $X \sim N(\mu,1)$，让我们来推导 μ 的 posterior。

$$
\begin{aligned}
p(\mu|X) &\propto \exp(-\mu^2/2))\exp(-\sum_i (X_i-\mu)^2/2) \\
&\propto \exp(-(\frac{N+1}{2}\mu^2 - \mu\sum_i X_i)) \\
&\propto \exp\left(-(\mu^2 - \frac{2\sum_i X_i}{N+1}\mu)/(\frac{2}{N+1})\right) \\
&\propto \exp\left((\mu - \frac{\sum_i X_i}{N+1}^2/\frac{2}{N+1}\right)
\end{aligned}
$$

结论

- $\mu|X \sim N(\frac{\sum_i X_i}{N+1}, \frac{1}{(N+1)^2})$。
- 换句话说，posterior 也是正态分布。
- 这种称之为 Conjugate Priors。

贝叶斯方法的好处和坏处

极客大学

- 好处：
  - 很方便的处理隐变量
  - 可以对不确定性进行估计
- 坏处：计算麻烦 $\rightarrow$ 就目前深度学习应用来说，最方便的是变分法。我们将通过介绍 VAE 的方式介绍该方法。

大纲

极客大学

1. 怎样学数学
2. 机器学习的各种角度和建模流程
3. 概率论和统计学复习
4. 极大似然估计
5. 贝叶斯估计和变分贝叶斯
   - 贝叶斯估计
   - 变分贝叶斯法
6. 矩阵和张量求导

大纲

极客大学

1. 怎样学数学
2. 机器学习的各种角度和建模流程
3. 概率论和统计学复习
4. 极大似然估计
5. 贝叶斯估计和变分贝叶斯
6. 矩阵和张量求导